INFORME TÉCNICO: EVALUACIÓN INTEGRADORA — PARTE 2

Entrenamiento Especializado de YOLOv8, Tracking con ByteTrack, Referencias Urbanas y Validación Aérea con Dron

Materia / Institución:	Visión por Computadora — Lic. en Inteligencia Artificial | Universidad Blas Pascal (UBP)
Integrantes:	Dennis Nelson Fernández (Legajo 189692) | Marcos Andrés Wamba Ferreyra (Legajo 190802)
Docente a cargo:	César Osimani
Repositorio Oficial & Colab:	GitHub: https://github.com/fernandezdennis/vc-integrador-ubp | Ejecución Zero-Touch en Google Colab con variable USE_SHORT_VIDEOS

RESUMEN EJECUTIVO: : El presente informe documenta la Segunda Parte de la Evaluación Integradora de Visión por Computadora. Se aborda la transición desde un detector genérico COCO hacia un modelo especializado YOLOv8n fine-tuned sobre el dataset propio curado Dataset V2 (588 imágenes anotadas con 7 clases urbanas: automovil, utilitario, pickup, camion, person, motorcycle, bicycle). Se integra un motor de seguimiento temporal con ByteTrack para la asignación de identificadores de tracking persistentes (track_id), un discriminador cromático en espacio HSV combinado con dispersión espacial (spread) para la identificación de vehículos rojos, y un marco espacial de referencias urbanas compartidas. Finalmente, se evalúa la generalización del sistema frente a tomas aéreas dinámicas de dron (drone_ok.mp4), analizando el fenómeno de Dataset Drift y justificando la calibración del umbral de confianza en conf=0.70. El proyecto cumple con la arquitectura MLOps Zero-Touch 100% reproducible en Google Colab y GitHub.

1. Introducción y Objetivos de la Parte 2

En el monitoreo inteligente de tráfico urbano, los detectores preentrenados genéricos (como YOLOv8 sobre el conjunto COCO) presentan limitaciones significativas al enfrentar categorías vehiculares locales específicas o ángulos de visión atípicos. La primera etapa del proyecto estableció un pipeline inicial de captura, sincronización multi-cámara a 15 FPS y filtrado cromático HSV. La Parte 2 eleva la capacidad predictiva y la riqueza analítica del sistema construyendo una solución completa de nivel profesional. (utilizando parámetros calibrados de ratio_threshold=0.12 y spread_threshold=0.25 para robustez frente a reflejos).

Objetivos centrales de la Parte 2:

- **Entrenamiento de un detector especializado:** Ajustar una red YOLOv8n sobre un dataset propio curado y reetiquetado (Dataset V2) enfocado en categorías de tránsito local: automovil, utilitario, pickup, camion, person, motorcycle y bicycle.

- **Seguimiento temporal con ByteTrack:** Asignar y sostener la identidad de cada objeto mediante identificadores locales (track_id) a lo largo de las secuencias de video de cada cámara, reduciendo parpadeos y dobles conteos.
- **Modelo espacial de referencias urbanas:** Mapear la posición de los vehículos respecto a puntos clave permanentes (Monumento San Martín, Kiosco, Contenedor de Obra) y segmentos de calzada (Líneas de semáforo, Sendas peatonales), posibilitando la asignación de identidades globales (global_track_id) entre sensores.
- **Identificación cromática mejorada:** Evaluar la presencia de carrocería roja integrando máscaras en espacio HSV y análisis de dispersión espacial (spread) directamente sobre las regiones de interés trazadas por el tracker.
- Validación a bordo de plataforma aérea (Dron): Evaluar el desempeño del modelo sobre tomas dinámicas móviles (drone_ok.mp4), diagnosticando el fenómeno de Dataset Drift provocado por el ángulo cenital/oblicuo y la falta de cámara fija. Durante la evaluación experimental en el tramo de control aéreo, el sistema registró un total de 18 vehículos contados cruzando la línea virtual de auditoría de tráfico.
- **Despliegue reproducible MLOps Zero-Touch:** Consolidar el notebook final VC_EVALUACION_INTEGRADORA_PARTE2.ipynb desacoplado en GitHub con descarga automática de recursos desde Google Drive mediante gdown.

2. Curación, Estructura y Balance del Dataset V2

Para responder a las necesidades específicas de la intersección estudiada, se transformó el dataset original mediante herramientas desarrolladas a medida (editor_yolo.py, editor_yolo_v2.py y convertir_dataset_v2.py). Este proceso reestructuró las etiquetas originales de COCO hacia un esquema taxonomy especializado de 7 clases definidas en classes.txt y configuradas en configs/data.yaml.

2.1 Estructura y Partición de Datos

El conjunto de datos comprende un total de 588 imágenes anotadas manualmente en formato YOLO normalizado. Siguiendo las buenas prácticas de visión por computadora, se aplicó una partición de 80% para entrenamiento y 20% para validación independiente:

- **Subconjunto de Entrenamiento (images/train y labels/train):** 470 imágenes con sus correspondientes archivos de anotación de texto (.txt).
- **Subconjunto de Validación (images/val y labels/val):** 118 imágenes utilizadas para la auditoría de métricas durante y al finalizar las 100 épocas de entrenamiento.

2.2 Balance de Clases en Entrenamiento

El inventario de instancias anotadas en el conjunto de entrenamiento (labels/train) evidencia la distribución real del flujo vehicular en la rotonda municipal, caracterizada por un marcado predominio de automóviles particulares:

Clase ID	Nombre de la Clase	Instancias en Train
0	person	304
1	automovil	1078
2	utilitario	58
3	pickup	219
4	camion	12
5	motorcycle	23
6	bicycle	25

Análisis de Balance: La clase 'automovil' representa la categoría dominante (1078 muestras), asegurando una alta capacidad de generalización. Las clases 'utilitario', 'pickup' y 'person' poseen un volumen adecuado, mientras que 'motorcycle' y 'bicycle' reflejan la baja frecuencia observada en las tomas urbanas reales.

3. Entrenamiento, Métricas y Evaluación del Modelo YOLOv8n

Se ejecutó el proceso de fine-tuning utilizando la arquitectura ligera YOLOv8n (Nano) preentrenada en COCO. El entrenamiento se configuró durante 100 épocas con resolución de entrada imgsz=640, tamaño de lote batch=16, optimizador automático AdamW (learning rate inicial lr0=0.000909) y aumentación de datos mediante Albumentations (Blur, MedianBlur, CLAHE, ToGray) y Mosaic (desactivado en las últimas 10 épocas).

3.1 Evolución de las Pérdidas de Entrenamiento

A lo largo de las 100 épocas registradas en training/vc_vehiculos-4, las funciones de pérdida mostraron una convergencia suave y estable sin señales de sobreajuste (overfitting):

- **Pérdida de Bounding Box (box_loss):** Descendió desde 0.9971 en la época 1 hasta 0.5074 en la época 100, indicando un ajuste geométrico preciso del encuadre.
- **Pérdida de Clasificación (cls_loss):** Se redujo drásticamente de 3.4480 a 0.3683, reflejando que el modelo aprendió a diferenciar eficazmente las 7 categorías.
- **Pérdida de Distribución Focal (dfl_loss):** Evolucionó de 0.8852 a 0.7992, afinando la precisión en los bordes de las cajas delimitadoras.

3.2 Métricas Finales de Validación (best.pt)

La evaluación cuantitativa sobre el conjunto de validación independiente (118 imágenes y 497 instancias reales) arrojó los siguientes resultados consolidados de desempeño:

Clase / Categoría	Imágenes	Instancias	Precisión (P)	Recall (R)	mAP50
GLOBAL (all)	**118**	**497**	**0.828 (82.8%)**	**0.727 (72.7%)**	**0.833 (83.3%)**
person	41	92	0.984 (98.4%)	0.679 (67.9%)	0.891 (89.1%)
automovil	110	304	0.921 (92.1%)	0.885 (88.5%)	0.958 (95.8%)
utilitario	17	17	0.923 (92.3%)	0.701 (70.1%)	0.845 (84.5%)
pickup	58	69	0.742 (74.2%)	0.710 (71.0%)	0.779 (77.9%)
camion	—	—	—	—	—
motorcycle	9	9	0.690 (69.0%)	0.556 (55.6%)	0.722 (72.2%)
bicycle	6	6	0.706 (70.6%)	0.833 (83.3%)	0.802 (80.2%)

Interpretación de Métricas: El modelo alcanzó un mAP50 global de 0.833 (83.3%) y mAP50-95 de 0.635. La clase 'automovil' sobresale con un mAP50 de 95.8% y Recall de 88.5%. En 'person' la Precisión es prácticamente perfecta (98.4%), lo que significa que el detector casi nunca comete falsos positivos al detectar peatones. El rendimiento en 'utilitario' (84.5%) y 'pickup' (77.9%) demuestra la efectividad de separar el tráfico en categorías comerciales específicas.

4. Motor de Tracking (ByteTrack) e Integración del Pipeline

Para transformar las detecciones cuadro a cuadro en eventos continuos con persistencia temporal, se integró el algoritmo ByteTrack (bytetrack.yaml). A diferencia de los rastreadores tradicionales que descartan detecciones con bajo score de confianza, ByteTrack preserva cajas de baja confianza para recuperar objetos temporalmente ocluidos o borrosos por movimiento.

4.1 Estructura del Evento Enriquecido

Por cada fotograma procesado, el pipeline (pipeline_generico.py) genera una estructura de evento unificada que contiene:

- **Timestamp temporal (timestamp):** Tiempo transcurrido en segundos formateado a 15 FPS (paso dt = 0.0667s).
- **Cámara de origen (camera):** Identificador local del sensor (calle, piso3, muni).
- **Identificador de Tracking Local (track_id):** ID entero persistente asignado por ByteTrack dentro de la secuencia de esa cámara.
- **Clase detectada (class):** Categoría predicha por best.pt (automovil, utilitario, pickup, camion, etc.).
- **Discriminación de Color Rojo (is_red):** Flag booleano (True/False) calculado mediante utils_color.py evaluando el espacio HSV y el spread espacial.
- **Referencia Urbana Asociada (reference):** Landmark o segmento espacial más cercano asignado por camara_rois_v2.py (ej. Monumento_San_Martin, Linea_Semaforo1).
- **Geometría Normalizada (xc, yc, bw, bh):** Coordenadas del centro y dimensiones del bounding box relativas a la resolución de la imagen.

4.2 Discriminador Cromático Dual (HSV + Spread)

El módulo utils_color.py mantuvo la regla de decisión evaluada en la Parte 1 sobre los recortes (ROIs) extraídos por el tracker: la combinación de la máscara en espacio HSV (rangos [0,10] y [170,180]) con un umbral de dispersión espacial (ratio_threshold=0.12, spread_threshold=0.25). Esta regla demostró descartar exitosamente falsos positivos provocados por luces de freno traseras en vehículos blancos o grises.

5. Modelo Espacial de Referencias Urbanas Compartidas

En intersecciones complejas, las coordenadas en píxeles son estrictamente locales para cada cámara. Para construir un puente geométrico entre sensores, se incorporó un modelo espacial basado en referencias urbanas permanentes (referencias_urbanas.py y camara_rois_v2.py).

5.1 Tipología de Referencias

- **Referencias Puntuales (POINT):** Puntos fijos del mobiliario urbano con un radio de influencia r (ej. Monumento_San_Martin cx=0.63, cy=0.54, r=0.08; Kiosco; Contenedor_Obra).
- **Referencias Lineales / Segmentos (SEGMENT):** Líneas de cruce y límites de carril definidos por extremos (p1, p2) con un ancho de tolerancia (ej. Linea_Semaforo1, Senda_Peatonal_Diagonal_Alvear, Senda_Peatonal_Kiosco).

5.2 Generación de Identificadores Globales (global_track_id)

Al procesar los 103,708 eventos consolidados de las tres cámaras (eventos_total.csv), la celda orquestadora genera la firma espacial y mapea cada track_id local hacia un identificador global (global_track_id: G1, G2, G3...).

Muestra de distribución de eventos unificados por referencia y firma espacial (eventos_total.csv):

- **automovil_False_None:** 39,719 eventos (Automóviles comunes en flujo libre fuera de referencias).
- **person_False_None:** 12,736 eventos (Tránsito peatonal continuo).
- **pickup_False_None:** 9,547 eventos (Pickups en circulación).
- **automovil_False_Senda_Peatonal_Diagonal_Alvear:** 7,900 eventos (Vehículos atravesando el cruce peatonal en Cámara Piso 3).
- **automovil_False_Linea_Semaforo1:** 4,459 eventos (Vehículos detenidos o cruzando la línea de semáforo en Calle y Muni).
- **automovil_True_None:** 4,128 eventos (Vehículos rojos detectados afirmativamente en flujo libre).
- **automovil_True_Linea_Semaforo1:** 2,455 eventos (Vehículos rojos cruzando la línea de semáforo).

6. Validación en Perspectiva Aérea con Dron (drone_ok.mp4)

Como prueba de fuego para evaluar la generalización del sistema frente a condiciones no observadas en el entrenamiento, se procesó el video aéreo tomado desde una plataforma móvil (drone_ok.mp4 y drone_ok_1min.mp4).

6.1 Diagnóstico de Dataset Drift

Al cambiar la cámara estática por un dron en movimiento con ángulo cenital/oblicuo pronunciado, el modelo se enfrenta a una alteración en la escala y perspectiva de los objetos (Dataset Drift). En las pruebas iniciales con el umbral por defecto (conf=0.25), aparecieron detecciones espurias sobre elementos urbanos no presentes en el dataset de entrenamiento (baños químicos de obra, cartelería frontal y estructuras de vereda).

6.2 Calibración del Umbral de Confianza (conf=0.25 vs conf=0.70)

Se ejecutó una evaluación comparativa cuadro por cuadro (sección 16.3 del notebook) comparando el comportamiento de las detecciones al elevar el umbral a conf=0.70. El análisis con la distribución boxplot de confianzas confirmó que:

- **Efecto de conf=0.70:** Suprimió prácticamente el 100% de los falsos positivos en señalización y obras, conservando la detección estable de vehículos reales (automovil, pickup, utilitario) con confianzas superiores al 85%-92%.
- **Limitación persistente:** Se constató que un umbral elevado filtra artefactos débiles, pero no elimina completamente las confusiones estructurales cuando el objeto tiene alta similitud visual con vehículos. Esto reafirma la recomendación de la materia de incorporar imágenes aéreas etiquetadas en futuras versiones del dataset.

6.3 Conteo de Cruce y Referencias desde el Dron

Debido a que la plataforma es móvil, las coordenadas absolutas en píxeles cambian en cada frame. Sin embargo, al asociar las referencias permanentes del entorno (REFERENCIAS_DRONE: Monumento_San_Martin, Cruce_Principal y Senda_Peatonal_Principal) e integrar una línea de conteo transversal (limits = [523, 397, 973, 397]), el sistema registró exitosamente el paso de 18 vehículos con tracking activo en el video aéreo (drone_tracking70full.mp4).

7. Arquitectura MLOps Zero-Touch y Estructura del Repositorio

El proyecto fue empaquetado bajo un esquema de producción desacoplado en dos capas para cumplir estrictamente con los criterios de reproducibilidad exigidos por la cátedra:

- **Repositorio Público en GitHub (vision-computadora-integrador):** Aloja el código Python (/scripts/), configuraciones (/configs/data.yaml), cuadernos (.ipynb) y dependencias (requirements.txt).
- **Almacenamiento Público en Google Drive:** Aloja el archivo recursos_integrador.zip con los datos pesados (dataset_v2/, pesos/best.pt, videos/).
- **Ejecución Zero-Touch en Google Colab:** El docente abre el cuaderno VC_EVALUACION_INTEGRADORA_PARTE2.ipynb, presiona 'Ejecutar todas' y la primera celda clona el repo, instala requerimientos, descarga los datos vía gdown (ID: 1LYbi_6j_vkI3yHYAu3ZWEFRjRxhW6PRt) y ejecuta el pipeline de extremo a extremo sin intervenciones manuales.

8. Matriz de Responsabilidades MLOps del Equipo

La distribución de tareas entre los integrantes se estructuró de la siguiente manera:

- **Dennis Nelson Fernández (Legajo 189692):** Curación e ingeniería de conversión del Dataset V2 (editor_yolo_v2.py); entrenamiento de YOLOv8n durante 100 épocas; integración del motor ByteTrack; desarrollo del script de visualización de referencias urbanas; automatización del entorno Zero-Touch con gdown en Colab.
- **Marcos Andrés Wamba Ferreyra (Legajo 190802):** Auditoría de balance de clases en train/val; validación empírica del umbral de confianza (conf=0.25 vs 0.70) en el video del dron; análisis de cajas y confusiones; mapeo de referencias urbanas en camara_rois_v2.py; redacción del informe técnico final.

9. Discusión Técnica, Límites del Prototipo y Factibilidad Operativa

1. **Frontera del Alcance del Modelo Entrenado (*Domain Boundaries*):**
   El modelo especializado best.pt demostró una precisión y estabilidad notables en las tres perspectivas terrestres urbanas fijas para las que fue diseñado. La prueba sobre la perspectiva aérea (drone_ok.mp4) se ejecutó como un ensayo de estrés para evaluar los límites de generalización del detector. Los desvíos observados responden al cambio de ángulo cenital y ángulo de incidencia respecto a las tomas terrestres. Queda técnicamente determinado que para un despliegue exclusivamente aéreo bastaría con enriquecer el dataset con tomas cenitales, lo cual excede el alcance del sistema de monitoreo vial terrestre implementado.
2. **Viabilidad de Proyección Espacial e Infraestructura:**
   La incorporación de referencias urbanas compartidas y landmarks permanentes resolvió la continuidad semántica inter-cámara sin sobrecargar el pipeline computacional. Si bien un mapeo planar estricto por homografía es una técnica conocida, su aplicación sobre plataformas móviles (drones sin telemetría RTK sincronizada) introduce inestabilidad matricial acumulativa y un costo computacional innecesario para los requerimientos de conteo y tracking fijados.
3. **Eficiencia en Inferencia vs. Modelos de Gran Escala (*Zero-Shot / Foundation Models*):**
   Se evaluó la literatura y pertinencia de arquitecturas open-vocabulary (como Grounded SAM o SAM 2) sugeridas en la bibliografía de actualización. Se concluye que, frente a la restricción operativa de procesar 15 cámaras concurrentes en tiempo real a 15 FPS, la combinación de YOLOv8n + ByteTrack + heurística HSV/Spread constituye la arquitectura óptima en la frontera de Pareto (compromiso precisión/latencia), mientras que SAM 2 demandaría una infraestructura de servidores de cómputo desproporcionada para el caso de uso municipal.

10. Conclusiones de cierre

Conclusiones principales del proyecto integrador:

- **Precisión del modelo especializado:** El fine-tuning de YOLOv8n sobre Dataset V2 demostró un salto cualitativo respecto al baseline genérico COCO, alcanzando un mAP50 de 83.3% global y 95.8% en automóviles.
- **Continuidad temporal con ByteTrack:** La integración del tracker otorgó estabilidad a las detecciones y permitió estructurar 103,708 eventos enriquecidos con track_id y referencias urbanas asociadas.
- **Discriminación cromática efectiva:** El algoritmo HSV + spread descartó con éxito la confusión producida por luces de freno en vehículos no rojos.
- **Robustez MLOps:** Se garantizó una ejecución 100% autónoma y reproducible Zero-Touch en Colab y GitHub.
- Con la implementación del modelo entrenado multiclase (best.pt), el tracking temporal persistente por cámara, la clasificación cromática robusta y la estructuración del registro enriquecido de eventos, **el proyecto da por cumplidos y finalizados la totalidad de los requerimientos y resultados de aprendizaje previstos para la materia**.